

Прогнозирование спроса на товары в следующем месяце (Amazon)

MDS
2025

Введение

Бизнес-проблема

Как предсказать спрос (количество покупок) на товары по категориям, чтобы оптимизировать запасы и избежать дефицита или перепроизводства?

Неправильное планирование запасов ведёт к потерям: либо из-за нехватки товаров, либо из-за излишков, что увеличивает издержки и снижает прибыль.

Цель проекта


Мы планируем построить модель, которая сможет прогнозировать спрос на товары по категориям на **следующий месяц**, используя исторические данные о продажах Amazon (чеки и заказы).

Такой прогноз поможет бизнесу принимать более обоснованные решения по управлению запасами и улучшить эффективность логистики.

Про данные

- Смотрим данные о продажах по западным штатам США
- Данные с 2011 по 2014 год

Суммарные заказы по штатам США



Про столбцы в исходном датасете

Название в датасете	Значение	Пояснение
Order Date	Дата оформления заказа	Дата, когда пользователь оформил заказ
Ship Date	Дата отправки заказа	Дата, когда товар был отправлен
Email_ID	Электронная почта пользователя	Адрес электронной почты, с которого был сделан заказ
Geography	Географическое расположение заказов	Город, откуда был сделан заказ
Category	Категория продукта	Тип товара (например, мебель, техника и т.д.)
Product Name	Название продукта на Amazon	Полное наименование товара
Sales	Сумма продаж продукта на Amazon	Общая выручка от продажи конкретного товара
Quantity	Количество единиц продукта	Сколько штук этого товара было в заказе
Profit	Прибыль с продаж продукта на Amazon	Чистая прибыль после вычета расходов на доставку, себестоимость и т.п.


Краткое содержание подпроблем

1. Прогноз количества покупок (Quantity)
2. Определить, снизится ли спрос
3. Выявление ключевых факторов
4. Учет сезонности и временной динамики

Подпроблемы 1 и 4 отвечают на вопросы "что" и "когда" (прогноз количества с учетом времени)

Подпроблема 2 — на "снизится ли" (управление рисками)

Подпроблема 3 — на "почему" (объяснение факторов спроса)



В совокупности позволяет оптимизировать запасы и избежать дефицита или перепроизводства

Подпроблема 1: Прогноз количества покупок

Цель: построить модель для прогнозирования количества продаж по категориям товаров на следующий месяц на основе исторических данных

1 шаг: подготовка данных:

- преобразование даты заказа в формат datetime
- извлечение года и месяца из даты
- агрегация данных по категориям и месяцам

2 шаг: создание признаков:

- лаговые признаки (продажи за предыдущие 1, 2, 3 и 12 месяцев)
- кодирование категорий товаров
- удаление пропусков после создания лагов

3 шаг: построение модели:


- линейная регрессия на лаговых признаках
- разделение данных на обучающую и тестовую выборки без перемешивания (для сохранения временного порядка)
- оценка качества модели с помощью метрик MSE, MAE, R^2 , Max Error

Базовая модель

Features: Lag_1, Lag_2, Lag_3, Lag_12, Category_encoded

Target: Quantity

Метрика	Значение
RMSE	15,3
MAE	10,7
R2	0,6
Max error	59,2



Улучшение модели


Предобработка данных

- Исключены наблюдения за пределами 5%-95% перцентилей
- Масштабирование (StandardScaler)

Улучшенные признаки

- Category_Avg (средние продажи по категории)
- Month_Avg (медиана продаж по месяцам)
- Trend (порядковый номер месяца для категории)
- Lag_1_Ratio (отношение лага к среднему по категории)

Метрика	Базовая модель	После улучшения	Изменение
RMSE	15,3	9,7	-36%
MAE	10,7	7,8	-27%
R2	0,6	0,4	-32%



Итоговые выводы и бизнес-инсайты (1)

Линейная модель - прогноз количества покупок

Модель можно использовать для:

- Планирования запасов по крупным категориям (ошибка ± 10 ед.).
- Автоматизации заказов там, где допустима погрешность 10-15%.

Требуется доработка для:

- Товаров с малым спросом.
- Ситуаций, где важны неучтенные факторы (акции, конкуренция).

Линейные ограничения

Модель предполагает, что все зависимости линейны, но в реальности могут быть нелинейные эффекты (например, акции дают прирост продаж только после определенного порога скидки).

Подпроблема 2: Определить, снизится ли спрос

Цель: предсказать, упадет ли спрос в следующем месяце (binary: да/нет)

Шаг 1: Подготовка данных

- Извлечение года и месяца для временной агрегации
- Группировка данных по категориям товаров и месяцам



Шаг 2: Создание признаков

- Лаговые признаки: Продажи за предыдущие 1, 2, 3, 6, 12 месяцев
- Кодирование категорий
- Удаление пропусков после генерации лагов

Шаг 3: Построение модели (Random Forest, Balanced Random Forest, catBoost)

- настройка baseline
- улучшение параметров - сбалансировать классы
- сравнение метрик - концентрируемся на ловле спадов


Базовая модель - Random Forest



Видим, что модель хорошо определяет только отсутствие спада. Поэтому необходимо сбалансировать recall для спада.

Улучшенная модель - Balanced Random Forest

Метрики модели BalancedRF




BalancedRF
Матрица ошибок (Accuracy: 0.64)



recall хорош, но много ложных тревог

Финальный вариант - CatBoost

Метрики модели CatBoost




CatBoost
Матрица ошибок (Accuracy: 0.71)



модель демонстрирует лучший процент найденных спадов и меньше ложных срабатываний

Сравнение моделей по ключевым метрикам



- Выбор модели зависит от цели. CatBoost снижает риск пропуска спадов на 58% при приемлемом уровне ложных тревог.
- это позволит оптимизировать количество товаров на складе и закупочные процессы.

Подпроблема 3: Выявление ключевых факторов

Цель:Объяснить, какие **признаки влияют на уровень спроса (Quantity)**, чтобы понять поведение клиентов и сформулировать бизнес-правила.

Шаг 1: Подготовка данных

- Сбор, очистка, **удаление утечек**.
- Создание признаков, кодирование категорий, масштабирование.

Шаг 2: Обучение моделей и выбор лучшей


- **Decision Tree** ($R^2 \sim 0.69$): Для **интерпретируемых правил**.
- **Random Forest (Базовый)** ($R^2 \sim 0.72$): Отправная точка.
- **Random Forest (Оптимизированный)** ($R^2 \sim 0.63$): **Финальная модель**, достигнутая через RandomizedSearchCV.

Шаг 3: Интерпретация и выводы для бизнеса

- Анализ **важности признаков** (feature_importances_) и графиков зависимостей.
- **Формулирование бизнес-правил** на основе инсайтов.

Сравнение базовых моделей: Decision Tree vs Random Forest

Дерево решений (max_depth=6)



- **Производительность:** $R^2 \approx 0.69$ (умеренная).
- Подходит для интерпретации базовых правил (например, `Sales <= 17.576`, то `~2.65` единиц), позволяет извлечь прямые бизнес-правила

Random Forest (base) vs Random Forest (RandomizedSearchCV)

Предобработка данных

- Обработка выбросов (IQR-фильтрация)
- One-Hot Encoding
- Масштабирование числовых признаков

Улучшенные признаки

- IsWeekend: Показывает, был ли заказ в выходной день
- IsFastShipping: Индикатор быстрой доставки (≤ 2 дня)
- DiscountRate: Отношение Profit к Sales
- HighValueOrder: Индикатор крупного заказа по сумме (Sales выше медианы).
- ShippingGapCategory: Категории времени доставки (например, Fast, Medium, Slow)

Метрика	Базовая модель	Randomized SearchCV	Изменения, %
MAE	0,7	0,9	-28,6%
RMSE	1,2	1,1	-8,3%
R2	0,7	0,6	-14,3%

модель стала ошибаться сильнее в абсолютных значениях

модель стала реже совершать большие промахи, но чаще ошибаться в целом

качество предсказаний упало


Анализ важности признаков (feature_importances_)

Главные драйверы спроса:

- Наибольшее влияние оказывают признаки **Sales**, **ProfitPerItem** и **DiscountRate**.

Визуальный анализ:

- Зависимость Quantity от **Sales** и **ProfitPerItem** нелинейна и с выбросами, но общая тенденция положительная.
- Повышение скидки (**DiscountRate**) сопровождается ростом Quantity.
- Некоторые категориальные признаки, как **ProductGroup_Office** или **Category_Binders** и демонстрируют отличия в средних значениях Quantity.



Подпроблема 4: Учет сезонности и временной динамики

Шаг 1: Подготовка данных

- Извлечение года и месяца для временной агрегации
- Группировка данных по категориям товаров и месяцам

Шаг 2: Обучение моделей и выбор лучшей

- **ARIMA** ($R^2 \sim -0.55$) - плохо прогнозирует
- **SARIMA (Базовые параметры)** ($R^2 \sim 0.515$): Отправная точка.
- **SARIMA (Оптимизированный)** ($R^2 \sim 0.88$)
- **Prophet** ($R^2 \sim -0.27$)

Шаг 3: Интерпретация и выводы для бизнеса

- **Формулирование бизнес-правил** на основе инсайтов.

Модели ARIMA и SARIMA

Предобработка данных:

- Группировка по месяцам
- Группировка по категориям

Улучшение моделей:

- Подбор оптимальных параметров для моделей
- Добавление экзогенных переменных (небольшие изменения)

Метрика	ARIMA	SARIMAX	SARIMAX оптимальны й	Изменение
MSE	28163.04	8804.14	2172.07	-75%
MAE	153.38	89.61	33.62	-62%
R2	-0.550	0.515	0.880	+71%

Общий прогноз

Подобрали лучшие параметры $\text{order}=(0, 2, 1)$, $\text{seasonal_order}=(0, 1, 2, 12)$



MSE: 2172.07


MAE: 33.62

R^2 : 0.880

По категориям


Группа: Furniture, Лучшие параметры: order=(0, 2, 1), seasonal_order=(2, 1, 2, 12), R2=0.837, MAE=15.90

Прогноз спроса для группы Furniture




Группа: Office, Лучшие параметры: order=(0, 1, 1), seasonal_order=(0, 1, 2, 12), R2=0.845, MAE=19.28

Прогноз спроса для группы Office




Группа: Leisure, Лучшие параметры: order=(1, 1, 0), seasonal_order=(1, 0, 1, 12), R2=0.445, MAE=14.92

Прогноз спроса для группы Leisure



Группа: Technology, Лучшие параметры: order=(0, 2, 1), seasonal_order=(1, 0, 1, 12), R2=0.158, MAE=13.32

Прогноз спроса для группы Technology



Основные выводы по временным рядам

- Качество предсказаний высокое с помощью модели SARIMA
- Необязательно использовать экзогенные переменные, так как они незначительно влияют на качество модели
- Prophet и ARIMA плохо справляются с предсказаниями
- Наименее предсказуемый спрос на технологии - он может быть сопряжен с выпуском отдельных крупных инновационных компаний, в то время как остальные категории товаров демонстрируют более устойчивые паттерны
- Есть тенденция роста спроса

Спасибо за внимание!

Приложение

приложение с метриками

Подпроблема 1:

прогноз количества покупок с помощью линейной регрессии

Суть линейной регрессии:

$$y = w_0 + w_1 * x_1 + w_2 * x_2 + \dots + e$$

где y - целевая переменная, x - признаки, w - коэффициенты при признаках

задача модели:

найти такие коэффициенты w , чтобы сумма квадратов ошибок mse была минимальной.

как обучается модель?

модель получает матрицу признаков x_{train} и вектор целевых значений y_{train} , затем вычисляет коэффициенты w , минимизируя mse

Базовая модель - что было сделано:

1. группировка данных по категориям, году, месяцу, агрегируя сумму продаж
2. добавление лаговых переменных - продажи за предыдущие 3 месяца
3. lag12 - продажи за тот же месяц год назад для учета сезонности
4. кодирование признаков
5. важно сохранить хронологический порядок при разбиении на train/test, чтобы избежать data leakage

Метрики:

Модель линейной регрессии демонстрирует умеренную производительность.

$R^2 = 0.633$ - Модель учитывает 2/3 факторов, влияющих на продажи (исторические данные, сезонность, категорийные особенности).

Оставшиеся 37% — это неучтённые элементы: маркетинговые акции, изменения цен, действия конкурентов, макроэкономические факторы.

Вывод: Модель уже полезна для базового планирования, но требует дополнения внешними данными.

RMSE = 15.21 - Средняя ошибка прогноза составляет около 15 единиц товара.

MAE = 10.73 - Средняя абсолютная ошибка около 11 единиц.

Max Error = 59.17 - Наибольшая ошибка в прогнозе составила ~59 единиц,

Риски:

- Для узких категорий: Это может привести к избытку запасов или дефициту.
- Для высокомаржинальных товаров: Упущенная прибыль или уценка излишков.

Улучшенная модель - что было сделано:

1. Добавление средних и медианных значений

- `Category_Avg` – средние продажи по каждой категории (помогает учесть разницу в масштабах между категориями).
- `Month_Avg` – медианные продажи по каждому месяцу (учитывает сезонность).

Это помогает модели понимать базовый уровень продаж для каждой категории и месяца.

- **Трендовый признак**

`Trend = groupby('Category').cumcount()` – номер месяца для каждой категории (позволяет модели учитывать долгосрочный тренд)

- **Относительные признаки**

`Lag_1_Ratio = Lag_1 / Category_Avg` – показывает, насколько прошлые продажи отклоняются от среднего уровня.

Это помогает модели нормализовать данные и лучше интерпретировать лаги.

1. Проверка корреляции добавленных признаков

Проблемы мультиколлинеарности Нет критических значений (все корреляции < 0.7)

Признаки Корреляция Интерпретация

- `Lag_1` и `Category_Avg` 0.55 Умеренная связь. Значит, средние продажи по категории частично объясняют последние продажи.
- `Lag_12` и `Category_Avg` 0.46 Слабая-умеренная связь. Годовой лаг содержит дополнительную информацию.
- `Trend` и `Lag_1` 0.37 Слабая связь. Тренд слабо связан с недавними продажами.

3. Удаление экстремальных значений

Отфильтровываем 5% самых низких и 5% самых высоких значений (`quantile(0.05)` и `quantile(0.95)`).

Это уменьшает влияние выбросов, которые могли исказить предсказания.

4. Масштабирование признаков — это критически важный этап подготовки данных для линейной регрессии.

- Корректная работа линейной модели

Линейная регрессия чувствительна к масштабу признаков, так как:

- Коэффициенты модели по сути отражают "цену" каждого признака

Признаки с большим диапазоном значений (например, `Lag_12`) будут искусственно получать больший вес

- Масштабирование выравнивает вклад всех признаков

`StandardScaler` - Центрирует данные (вычитает среднее) и Нормализует (делит на стандартное отклонение)

Метрики:

R^2 снизился с 0.63 до 0.43: Теперь модель объясняет только 43% колебаний продаж вместо прежних 63%.

Почему мог ухудшиться R^2 ?

- Убрали полезные признаки (например, лаги или средние значения).
- Добавили "шумные" или избыточные переменные.

Точность прогнозов улучшилась

RMSE снизился с 15.2 до 9.97: Средняя ошибка уменьшилась с ± 15 до ± 10 единиц товара.

MAE снизился с 10.73 до 7.88: Половина прогнозов теперь ошибается не более чем на 8 единиц (вместо 11).

Для товаров с малым спросом (до 50 ед./мес): Ошибка ± 10 единиц (20%) — требует ручной проверки.

Для товаров с объемом 100+ ед./мес: Ошибка 10% — приемлемо для автоматизированного планирования.

подпроблема 2: метрики

Метрика	Формула	Что измеряет?
Accuracy	$(TP + TN) / \text{Все наблюдения}$	Общая точность прогнозов
Precision	$TP / (TP + FP)$	Доля верных предупреждений о спаде
Recall	$TP / (TP + FN)$	Доля найденных реальных спадов
F1-Score	$2 * (Precision * Recall) / (Precision + Recall)$	Баланс между точностью и полнотой

подпроблема 2: ход анализа

Что сделали:

1. Определили целевую переменную (Demand_Drop):
Спад спроса = продажи в следующем месяце упали более чем на 10%.
2. Создали признаки:
Лаги продаж (Quantity_Lag_1, _2, _3).
Цена за единицу (PricePerUnit), покупки в выходные (IsWeekend).
3. Подготовили данные:
Удалили пропуски, преобразовали категориальные переменные.
Разделили на обучающую (1196 строк) и тестовую (299 строк) выборки без перемешивания.
4. Выявили дисбаланс классов:
83% — нет спада, 17% — спад → нужна балансировка модели.

построили базовую модель, подкрутили настройки, ограничили глубину 7 и минимальное количество элементов в выборке 5.

- Модель хорошо определяет отсутствие спада (Precision 78.6%)
- Обнаруживает только 36.4% реальных спадов (нужно улучшать)
- Общая точность 67.2% - лучше случайного предсказания

затем сбалансировали классы изменением модели и сконцентрировались на ловле самих спадов - даже ценой ложных тревог

подпроблема 3: Выявление ключевых факторов

Цель подзадачи:

Объяснить, какие признаки влияют на величину спроса (Quantity), чтобы:

- понять поведение клиентов;
- сформулировать бизнес-правила;
- улучшить прогнозирование заказов.

Методология:

- Выбор модели начинался с **дерева решений (Decision Tree)**:
 - обеспечивает прозрачную интерпретацию;
 - позволяет определить важные правила.
- После этого применен **Random Forest**:
 - повышает точность;
 - устраняет переобучение за счёт ансамбля;
 - сохраняет интерпретируемость через feature importance.

Почему Quantity:

- Задача — **предсказать спрос в единицах**, а не выручку или прибыль.
- Profit не используется, так как он зависит от Quantity → утечка данных.
- Sales = Quantity * Price_per_Item — тоже не включается в финальную модель.

Обработка данных:

- Удалены признаки-утечки: Profit, Sales (на этапе финальной модели).
- Обработаны выбросы через IQR-фильтрацию.
- Категориальные признаки закодированы через One-Hot Encoding.
- Order Date преобразован в timestamp.
- Данные разбиты на обучающую и тестовую выборки (test_size=0.2, random_state=2024).
- Все признаки численные, пропусков нет.

Метрика	Что измеряет	Интерпретация
MAE (Mean Absolute Error)	Средняя абсолютная ошибка	Чем меньше, тем точнее. Показывает, насколько в среднем модель ошибается в штуках.
RMSE (Root Mean Squared Error)	Корень из средней квадратичной ошибки	Более чувствительна к большим ошибкам. Также чем меньше — тем лучше.
R² (Коэффициент детерминации)	Доля объяснённой дисперсии	От 0 до 1. Чем ближе к 1, тем лучше модель объясняет зависимость.

подпроблема 3: Выявление ключевых факторов

Модель	MAE	RMSE	R ²	Вывод
Decision Tree	0.843	1.236	0.691	Простая модель. Объясняет 69% дисперсии, но неточная — ошибки выше, чем у случайного леса.
Random Forest (базовая)	0.737	1.181	0.721	Лучше дерева по всем метрикам. Более устойчива за счёт ансамбля деревьев.
Random Forest (оптимизированная)	0.925	1.180	0.635	Парадокс: R ² снизился, MAE ухудшился. Возможен оверфит или неудачная комбинация гиперпараметров.

- **Базовая модель Random Forest оказалась наиболее сбалансированной:**
 - минимальная ошибка (MAE, RMSE),
 - высокая объяснённая дисперсия ($R^2 = 0.721$).
- **Оптимизированная модель ухудшилась:**
 - возможно, `n_iter` или диапазон параметров был недостаточным;
 - либо модель начала переобучаться (лучше на train, хуже на test).
- **Decision Tree** — интерпретируемая, но менее точная альтернатива. **Базовая модель Random Forest оказалась наиболее сбалансированной:**
 - минимальная ошибка (MAE, RMSE),
 - высокая объяснённая дисперсия ($R^2 = 0.721$).
- **Оптимизированная модель ухудшилась:**
 - возможно, `n_iter` или диапазон параметров был недостаточным;
 - либо модель начала переобучаться (лучше на train, хуже на test).
- **Decision Tree** — интерпретируемая, но менее точная альтернатива.